

台灣電力股份有限公司 114 年度
研究計畫 546-2415-1305

應用預測技術優化電池儲能排程之研究 完成報告

台灣電力股份有限公司
中華民國 114 年 12 月

※※※※※※※※※※※※※※※※※※
※
※ 本報告書 ※
※ ※
※ ※
※ ※
※ 僅供參考 ※
※ ※
※ ※
※ 請勿轉載 ※
※ ※
※※※※※※※※※※※※※※※※※※

台灣電力股份有限公司
二十年度研究報告

應用預測技術優化電池儲能排程之研究

完成報告

應用預測技術優化電池儲能排程之研究

完成報告

研究方式：自行研究

執行期間：中華民國 113 年 1 月 1 日至 114 年 12 月 31 日

執行單位：綜合研究所

研究主持人：黃彥璟

研究人員：曹志明、張書維、張益彰、李盈家、陳俐安

摘要

本研究旨在探索人工智慧光伏發電預測技術在電池儲能排程應用中的潛力。我們利用無需程式碼的 AI 平台，採用 XGBRegressor 演算法建構輕量化的光伏發電預測模型，其模型數據來源整合了氣象觀測站公開資料、案場實際光伏量測數據以及時間序。模型建立後，接著導入中央氣象局的氣象預報資料，藉以生成案場的光伏發電預測結果，並將這些預測數據整合至現有能源管理系統（EMS）介面，實現預測與實際觀測數據的並列顯示，以利使用者進行比對與評估。

儘管本研究已初步達成與現有 EMS 的整合應用目標，然而我們也發現當前光伏發電預測模型的預測精準度仍有提升空間，以及關於電池儲能排程的優化，負載與電價等關鍵變數須被納入考量，這些因素將成為未來研究的重點。我們規劃在後續階段考量上述事項，以優化電池儲能排程，進而提升充放電策略的準確性與經濟效益。最終，本研究期望能協助案場的再生能源電力系統實現削峰填谷，利用電價差進行經濟調度，全面提升能源使用效率並降低整體用電成本。

Abstract

This study aims to investigate the potential of artificial intelligence (AI) in photovoltaic (PV) power generation forecasting and its application to battery energy storage scheduling. Utilizing a no-code AI platform, we developed a lightweight PV forecasting model using the XGBRegressor algorithm. The model integrates data sources including public records from weather stations, actual on-site PV measurement data, and temporal sequences. Following model construction, weather forecast data from the Central Weather Administration (CWA) was incorporated to generate PV power generation predictions for the site. These forecasts were then integrated into an existing Energy Management System (EMS) interface, enabling the side-by-side visualization of predicted versus actual observed data to facilitate user comparison and evaluation.

Although the initial objective of integrating with the existing EMS has been achieved, we observed that the prediction accuracy of the current PV forecasting model still leaves room for improvement. Furthermore, regarding the optimization of battery energy storage scheduling, key variables such as load demand and electricity tariffs must be taken into account; these factors will be the primary focus of future research.

We plan to address the aforementioned considerations in subsequent stages to optimize battery storage scheduling, thereby enhancing the precision and economic viability of charging and discharging strategies. Ultimately, this study aims to assist the site's renewable energy power system in achieving peak shaving and valley filling. By leveraging electricity price arbitrage for economic dispatch, we seek to comprehensively improve energy usage efficiency and reduce overall electricity costs.

關鍵詞：光電預測、AI、數據處理、儲能、能源管理系統

Keyword: Photovoltaic Forecasting; Artificial Intelligence; Data Processing; Energy Storage; Energy Management System (EMS)

目錄

圖目錄 IV

表目錄 IV

一、前言.....	1
1.1 研究背景與動機.....	1
1.2 研究目的.....	2
1.3 計畫執行範圍.....	3
二、文獻回顧.....	5
2.1 電池儲能系統(BESS)的關鍵角色與技術應用	5
(1) BESS 的必要性：解決再生能源間歇性與提升電網彈性	5
(2) 核心功能：削峰填谷、頻率調節與能量套利.....	7
(3) 台灣儲能產業的發展現況與挑戰.....	11
2.2 光伏發電預測技術與儲能排程的整合應用.....	13
(1) 預測技術回顧：特徵參數選用	13
(2) 預測技術回顧：主流模型與應用	16
(2) 傳統排程的局限性：經驗與即時反應的不足.....	20
(3) 預測技術的革新：實現儲能排程的「主動預見」	21
2.3 無程式碼 AI 平台在能源領域的應用	23
(1) 新興趨勢：降低技術門檻.....	23
(2) 優勢與挑戰：快速迭代、易於部署與客製化、數據安全性.....	24
三、研究方法.....	25
3.1 數據蒐集與前處理.....	25
3.2 光伏預測模型建立.....	26
3.3 能源管理系統導入與數據整合.....	29
四、研究結果與討論.....	30
4.1 總體預測準確度與訓練週期穩定性分析.....	31
(1) 決定係數(R^2)比較與模型解釋力評估	31
(2) 誤差指標 (RMSE/MAE)之不同時間尺度量化與差異分析	33
4.2 預測總量偏差與季節性探討.....	38
(1) 實際與預測總量對比的系統性偏差.....	38
(2) 季節性誤差模式與外部因子耦合分析.....	40
五、結論與未來工作.....	43
5.1 結論.....	43
5.2 未來工作.....	44
六、參考文獻.....	45

圖目錄

圖 1. 2024 年全球再生能源發電總裝置容量與新增量（按技術劃分）	1
圖 2. 削峰填谷的能源轉移	8
圖 3. XGBOOST 通用架構	18
圖 4. LSTM 網路結構	19
圖 5. No-CODE AI 平台介面簡介	27
圖 6. 不同時間跨度訓練數據所建立模型的決定係數比較	32
圖 7. 不同時間跨度訓練數據所建立模型之「每小時」誤差指標比較	36
圖 8. 不同時間跨度訓練數據所建立模型之「每日」誤差指標比較	37
圖 9. 標準誤差分佈型態	37
圖 10. 2022-2024 模型標準化誤差分佈型態比較	37
圖 11. 各時間跨度模型所得預測總發電量與實際觀測總發電量比較	40
圖 12. 春/夏季預測發電量誤差比較	42

表目錄

表 1. 電池儲能系統核心功能與效益對照表	10
表 2. 光伏預測核心輸入特徵參數總覽表	16
表 3. 不同時間跨度訓練數據所建立模型的誤差指標數值	38
表 4. 春/夏季不同時間跨度模型的預測發電總量及誤差	41

一、前言

1.1 研究背景與動機

全球能源架構正經歷一場重要的轉型，其核心驅動力源於氣候變遷的環境訴求，同時也深受地緣政治穩定與國家能源安全戰略的影響。在此背景下，再生能源尤其是太陽光電與風力發電，已成為各國確保能源自主性、提升經濟韌性的關鍵戰略選擇。根據 2025 年再生能源政策網絡研究機構（REN21）提出的報告¹，全球再生能源發電裝置容量再創歷史新高，其中太陽光電持續佔據主導地位(如圖 1)，顯示其蓬勃發展態勢。台灣也積極響應此趨勢，確立了「展綠、增氣、減煤、非核」的核心能源轉型原則，並訂定 2025 年再生能源發電佔比達 20 % 的政策目標。




圖 1. 2024 年全球再生能源發電總裝置容量與新增量（按技術劃分）

然而，大規模導入再生能源，特別是太陽光電，對傳統電力系統構成嚴峻挑戰。太陽光電具有「間歇性及不易預測性」的性質，其發電量受天氣影響可能在短時間內劇烈變化。依據本公司的調度經驗顯示，

太陽光電發電量曾在短短 3 小時內驟降 280 萬度，對電網的電壓、頻率穩定性造成巨大衝擊，並為傳統調度模式帶來極大考驗。傳統的電力調度模式難以應對這種不穩定性，可能導致機組效率降低、運維成本增加，甚至造成「棄光」的資源浪費現象。

為了解決上述挑戰，電池儲能系統 (BESS) 被視為維持電網穩定與提升能源利用效率的關鍵技術。BESS 因其快速響應能力，能夠有效地儲存過剩的太陽光電並在需要時釋放，從而平滑再生能源的波動性，並提供電網頻率調節等關鍵輔助服務。但單純依賴即時數據的被動式儲能排程，無法最大化儲能系統的潛力。

因此，本研究的動機在於將人工智慧光伏發電預測技術導入電池儲能排程，以實現從「被動響應」到「主動預見與優化」的轉變。透過預測未來的光伏發電量，並結合負載需求與電價資訊，儲能系統能夠提前規劃其充放電策略，不僅能更有效地平滑頻率波動、提升系統穩定性，更能最大化「削峰填谷」與「利用峰谷電價差進行經濟調度」的效益。

1.2 研究目的

本研究的目標為探索人工智慧光伏發電預測技術在電池儲能排程應用中的潛力，旨在將儲能系統從被動響應轉變為具備主動預見能力的智慧型資產，因此本階段研究具體確立以下目的：

- [1] 建立基礎光伏發電預測能力：建構一套輕量化光伏發電預測模型，嘗試克服再生能源間歇性與不易預測性的挑戰。
- [2] 實現數據整合與可視化：成功將模型生成的預測數據整合至現有能源管理系統（EMS）介面，以實現預測數據的可視化，為使用者提供決策支援。
- [3] 奠定優化研究基礎：透過介面功能實現預測與觀測數據的比對與評估，為後續模型精準度優化及更全面的智慧調度研究奠定基礎。

1.3 計畫執行範圍

本計畫的執行範圍明確界定為從基礎數據處理至將初步預測功能導入現有系統。主要工作內容如下：

- [1] 文獻與數據準備：蒐集並整理了來自中央氣象局的公開氣象資料以及案場實際的光伏量測數據。
- [2] 輕量化光伏發電預測模型建構：使用無需程式碼的 AI 平台，選擇 XGBRegressor 演算法，建置光伏發電預測模型，並成功生成發電預測結果數據。
- [3] EMS 系統整合：將前述預測數據導入現有的能源管理系統(EMS)介面，以實現預測數據與實際觀測數據的並列顯示功能。

本階段未包含下列項目，並將其視為未來研究的範圍：

- [1] 預測模型優化：本計畫所建置的模型為初步版本，其精準度仍有

提升空間，相關的優化與演算法調校工作將規劃於下一階段執行。

- [2] 電池儲能排程優化：本計畫的最終目標是建構優化電池儲能排程所需之模型，但現階段僅專注於光伏發電預測，負載與電價等其他關鍵變數尚未納入考量，將規劃於下一階段執行。

二、文獻回顧

全球能源轉型正加速進行，以應對氣候變遷和能源安全挑戰。再生能源，特別是太陽光電，在全球能源結構中的佔比持續增長，然而其固有的間歇性與波動性對電網的穩定性構成挑戰，促使電力系統對靈活性和韌性的需求日益增加。在此背景下，電池儲能系統（BESS）已成為解決再生能源整合問題的關鍵技術。同時，精準的光伏發電預測技術與儲能排程的深度整合，對於最大化 BESS 的效益至關重要。此外，隨著人工智慧技術的普及，無程式碼 AI 平台作為一種新興工具，正逐步降低 AI 應用的技術門檻，為能源領域的創新與優化提供了新的途徑。本章節旨在探討 BESS 的關鍵角色與技術應用、光伏發電預測技術與儲能排程的整合，以及無程式碼 AI 平台在能源領域的應用現況、優勢與挑戰，為未來研究與實踐奠定相關的文獻基礎。

2.1 電池儲能系統(BESS)的關鍵角色與技術應用

(1) BESS 的必要性：解決再生能源間歇性與提升電網彈性

太陽光電和風力發電等再生能源的發電量受氣候條件影響，對電力系統的穩定性帶來考驗。例如，台灣的太陽光電在下午 3 點到 6 點之間發電量可能急劇下降，在 2019 年的最高負載日就曾減少了 128 萬度，2020 年是 172 萬度，而 2021 年 7 月 27 日更足足掉了 280 萬度，

嚴重影響夜尖峰的供電穩定度²。未來越來越高比例的再生能源併網將會更嚴重地導致電壓、頻率不穩定或輸電壅塞，使得傳統基於負載預測的電力調度模式難以承受如此劇烈的變化。電池儲能系統(BESS)在此情境下扮演著核心角色，能夠於再生能源發電高峰（如白天日照充足時）儲存多餘電能，並在發電量不足或需求高峰時釋放，從而有效平滑化再生能源輸出，減少其對電網的衝擊。BESS 快速充放電的特性使其成為穩定電網頻率和電壓的關鍵工具，在電網頻率突變的緊急時刻，可作為「最佳救援投手」在毫秒級別內快速反應，穩定系統頻率。

在國際之間 BESS 容量正在快速增長。例如，美國的 BESS 裝機容量從 2020 年到 2024 年增長了 1025%，從 2.4 GW 達到 27 GW，預計到 2030 年將超過 170 GW，這主要得益於電池成本的持續下降和對電網靈活性日益增長的需求³。台灣也將儲能系統視為因應能源轉型、提高電網韌性的主要策略之一，目前電網端儲能裝置容量已達原先 2025 年 1000 MW 的目標，而發電端的儲能裝置容量(包含光儲合一)預計今年要達到 500 MW，並在 2030 年擴大至 2500 MW，以應對再生能源併網量增加帶來的挑戰。

BESS 被視為能源轉型的關鍵推手，但並非單一解決方案，其重要功能在於提升電網靈活性並儲存間歇性再生能源。然而，這些效益仍需與其他電網平衡機制，如需求反應、彈性發電和電網智慧化等措施，一併考量，也就是 BESS 的價值最大化是透過與更廣泛、更全面的電網管理策略整合而實現，例如加州電網的「鴨子曲線」現象，即中午太陽能發電過剩與傍晚用電需求急劇攀升之間的供需失衡，可透過 BESS 儲存日間過剩太陽能並在傍晚高峰時段放電來緩解，但這同樣需要多種解決方案的協同作用。^{4,5}

此外，BESS 的角色已從傳統的「備用電力」演變為「主動電網管理工具」。現代 BESS 部署不僅是備援，更是深度整合於電網之中，具備高度響應性和經濟效益。毫秒級的快速反應能力，使其能夠主動參與電網的實時平衡，例如協助電力平滑化和削峰填谷，成為夜尖峰解決方案。這種角色上的轉變，提升了開發和部署先進控制系統與複雜市場機制的重要性，以充分利用 BESS 的動態電網管理能力。

(2) 核心功能：削峰填谷、頻率調節與能量套利

電池儲能系統具備多項核心功能，使其在現代電力系統中不可或缺：

A. 削峰填谷 (Peak Shaving and Valley Filling)：

BESS 通過在電價較低或發電量過剩時（如再生能源高峰期）充電，並在電價高昂或需求高峰時放電，從而有效降低用戶的用電成本，也能避免因超過契約容量而產生的罰款。這種策略有助於平滑化電網的負載曲線，並減少對使用高成本化石燃料之火力發電廠的依賴，進而降低整體發電成本和碳排放。




圖 2. 削峰填谷的能源轉移

B. 頻率調節 (Frequency Regulation)：

BESS 具備毫秒級的快速反應能力，能夠自動即時偵測電網頻率的微小偏差，並依據預設的運轉曲線快速調整輸出功率（充電）。這種即時響應對於維持電網頻率在穩定範圍內至關重要。本公司的電力交易平台提供了多種調頻備轉服務，例如 dReg0.25、dReg0.5 和 E-dReg。其中 E-dReg（增強型動態調頻

備轉容量輔助服務) 結合了功率型和能量型電池的優勢，使其能夠在提供精確調頻服務的同時，也能實現電能轉移和削峰填谷功能，從而最大化系統效益和收益。這類服務不需接受電力調度單位指令，可在 1 秒內快速反應。

C. 能量套利 (Energy Arbitrage)：

BESS 利用不同時段的電價差異，在電價較低時段（如離峰時段或再生能源發電量充足導致批發電價較低時）儲存電能，並在電價高時段（如尖峰時段）將儲存的電能釋放回電網或供自身使用，從中獲取經濟收益。這種策略在電力市場化程度較高、電價波動較大的地區尤為重要，因為價格波動提供了更多的套利機會，顯著提升了 BESS 的財務吸引力。

輔助服務市場的設計對 BESS 的經濟價值和技術發展具有深遠影響。本公司電力交易平台提供的調頻備轉服務，如 E-dReg，因其結合了功率型和能量型電池的優勢，能夠同時提供精確調頻和削峰填谷功能，從而帶來更高的收益，這也直接激勵了複合型 BESS 的發展和部署。單純依賴能量套利往往不足以彌補 BESS 高昂的投資成本，因此參與電網服務對於其商業可行性十分重要⁶，持續地優化輔助服務市場機制，以反映 BESS 在電網穩定和經濟效益方面的真實價值，將是

推動 BESS 大規模應用的關鍵。

儲能系統的經濟效益也並非來自單一功能的優化，其價值與成功關鍵在於能整合多種服務來創造收益，例如 E-dReg 服務能夠將 dReg0.5 的調頻功能與削峰填谷結合，能夠同時參與能量套利和頻率調節服務，實現最大效益。這種收益疊加的方式，使得 BESS 能夠產生足夠的收入來抵消其高昂的資本成本，從而實現財務可行性。然而這樣的複雜性也凸顯了 BESS 對先進優化模型和智能控制系統的需求，藉由人工智慧和機器學習技術的導入，能夠動態地將 BESS 資源分配給當前最有利可圖或最關鍵的服務，勝過簡單的、單一目的的規則型方法。

功能名稱	運作機制簡述	對電網的影響	經濟效益
削峰填谷	在電價低或發電過剩時充電，高價或高峰時放電。	平滑負載曲線，減少對尖峰發電廠依賴，緩解電網壓力。	降低用電成本，避免超約罰款，提高能源利用率。
頻率調節 (AFC/FCR)	自動即時偵測頻率偏差，毫秒級快速充放電以穩定頻率。	維持系統頻率穩定，提供快速備轉容量，增強電網韌性。	參與輔助服務市場獲取收益，降低傳統機組運維成本。
能量套利	利用電價時段差異，低價買電儲存，高價賣電。	促進電力市場效率，減少棄光。	創造市場收益，提高資產利用率。
電網韌性/ 備用電力	在電網故障或發電不足時提供即時電力支援。	確保供電穩定，減少停電風險，支持關鍵基礎設施。	提升供電可靠性，降低事故損失。

表 1. 電池儲能系統核心功能與效益對照表

(3) 台灣儲能產業的發展現況與挑戰

台灣的能源轉型政策以「展綠、增氣、減煤、非核」為核心原則，旨在確保電力供應穩定、降低空污及減少碳排放。為此，政府在過去設定了今年（2025 年）再生能源發電占比須達 20 % 的政策目標，其中太陽光電裝置容量預計達到 20 GW，離岸風力裝置容量則達 5.7 GW 以上。截至 2025 年 4 月底，台灣已建置太陽光電裝置容量約 14.6 GW，離岸風力裝置容量則約 3 GW⁷。然而因應大規模再生能源併網，本公司規劃在 2025 年底前將儲能建置容量提升至 1000 MW，並將電能轉移服務容量目標設定為 2000 MWh，同時透過電力交易平台引導民間業者積極參與，共同為電網穩定貢獻力量。

此外，台灣也正積極推動電池儲能系統的國產化，尤其是在電池芯和功率調節系統 (PCS) 等核心零組件方面，以減少對進口的依賴並提升產業自主性。例如國家發展委員會的前瞻基礎建設計畫中，明確提出要推動百萬瓦級儲能系統的主要零組件供應商 80% 以上為國內廠商，並以中研院的鋰電池正極材料專利為核心，發展自有新型快充電芯，以期落實國造電芯之目標。

然而台灣儲能產業的發展仍面臨多重挑戰。首先，儘管本公司已啟動電力交易平台，但較為僵化的法規和有限的市場靈活性，這對電力市場的進一步自由化構成了挑戰⁸；其次，全球供應鏈重組、地緣政

治風險以及關鍵原物料成本上升，對台灣儲能產業鏈的本土化和規模化生產造成衝擊，例如鋰離子電池和全鈦液流電池的供應鏈和材料問題已阻礙了其大規模應用⁹；第三，BESS 屬於資本密集型產業，專案生命週期長達數十年，且需面對短期市場波動和複雜的融資結構，這使得企業在投入儲能領域時需要專業財務顧問的協助以進行風險控管¹⁰；最後，全球再生能源產業普遍面臨技術人員短缺的問題，這也可能影響台灣儲能產業的發展速度和技術創新能力。

以現階段來說，台灣再生能源和儲能的設置目標與實際產業發展情形仍有潛在差距，儘管 2025 年太陽光電 20GW 和儲能 1000MW 的目標雄心勃勃，但核心零組件的進口依賴、國內電芯產業經濟規模不足以及市場法規僵化等問題，都可能阻礙這些目標的實現。這也說明，要達成能源轉型目標，不僅需要從上而下的政策指導和資金投入外，更需要靈活的政策干預，以簡化法規、降低私營部門投資風險，並積極培育國內供應鏈能力，從而彌平理想與現實之間的差距。

儲能產業的發展同時受到電網穩定需求和企業 RE100 倡議的雙重驅動，除了電網運營商為系統穩定和再生能源整合而部署儲能外，RE100 倡議也扮演了關鍵角色，帶動企業積極導入儲能設施。全球許多 RE100 成員依賴台灣供應鏈以實現其綠電承諾，這種來自電網端和企業端的雙重需求，為儲能市場創造了強大的拉力。企業透過參與

虛擬電廠等方式提供「用電彈性」，協助電網維持供電穩定，同時將電力資產轉化為額外收益來源¹¹。這意味著台灣的 BESS 解決方案和市場設計必須同時滿足公用事業級電網服務和用戶側工商業應用，因此需要多樣化的產品、靈活的商業模式，以及能夠有效整合分散式能源資源的政策機制，以實現系統穩定和企業永續發展的雙贏目標。

2.2 光伏發電預測技術與儲能排程的整合應用

(1) 預測技術回顧：特徵參數選用

光伏發電功率的變化受到多種環境和系統因素的影響，將這些影響因素歸類並進行數據收集，是建立有效預測模型的基礎。然而特徵參數的選擇，不僅決定了預測模型的輸入維度，更決定了模型捕捉複雜物理現象（如天氣突變）的能力。因此，針對不同的預測時間區間（超短期、短期、中期）必須制定相應的特徵工程與選擇策略。

A. 核心氣象輸入特徵：輻射量與環境因子

太陽輻射是影響光伏功率輸出的最關鍵物理量，研究表明瞬時太陽輻射量的數值對於預測模型非常重要¹²。太陽輻射通常分為三種：全天空日射量（Global Horizontal Irradiation, GHI）、直達日射量（Direct Normal Irradiance, DNI）和擴散日射量（Diffuse Horizontal Irradiance, DHI）¹³。在實際應用中，GHI 是最常用的輸入特徵，因為它代表了

到達水平面的總日射量。然而許多研究採用 GHI 數據以及其他氣象因素（如溫度、濕度）的滯後變量（Lag Variables），也就是過去時刻的氣象觀測數據，作為模型的輸入特徵，藉以捕捉時間序列的自相關性¹⁴。此外，考慮到光電面板通常具有最佳傾斜角（例如 30 度），利用太陽高度角的變化來計算光電面板實際接收到的日射量也是一種重要的特徵工程步驟。

除了日射量外，環境氣象因子對光伏功率的間接影響同樣不容忽視。這些因子包括溫度、濕度、降水和雲量。其中，溫度不僅影響光電組件的運行效率，其預測的最大值也被視為重要的輔助預測特徵¹²。雲量則是最主要的波動來源，透過遮擋太陽光，導致功率輸出的劇烈變化。因此，準確地捕捉這些氣象因素的變化趨勢，是提升預測精度的必要條件。

B. 歷史功率數據與時間序列特徵

在統計和機器學習（ML）方法中，歷史數據是預測模型的核心輸入，直接預測模型（Direct Forecasting Models）主要利用歷史光伏輸出數據樣本進行預測，這類模型高度依賴時間序列的內在規律，包括：

1. 時滯變量（Lag Variables）：歷史 PV 功率輸出值、歷史氣象參數值等，用於訓練循環單元模型（如 LSTM）來捕捉時間相關性¹⁴。
2. 時序特徵：例如小時、星期幾、月份、季節等，這些週期性特徵

有助於模型識別規律性的發電模式，從而區分日常負載變化或季節性差異。

C. 針對特定時域的特殊數據與特徵

預測時域的長短直接決定了所需數據的類型和空間/時間分辨率。對於超短期預測（通常指未來數分鐘至一小時），由於時間分辨率要求極高，標準的數值天氣預報（NWP）模型的更新頻率和空間分辨率往往無法滿足需求。因此，超短期預測嚴重依賴於高頻的局部數據源，例如全天空影像、衛星影像和雷射雲幕儀（Ceilometers）數據。在利用圖像數據時，特徵工程變得尤為複雜且關鍵，例如有研究採用 HSV-SURF 算法快速從全天空影像序列中提取特徵點，追蹤雲團的運動軌跡。這種方法的核心是將雲團的空間移動訊息轉化為輻射係數，該係數能夠直觀地表徵下一時刻的輻射量情形。這類圖像處理技術是為了應對雲層快速移動所造成的瞬時功率驟變，確保在電網安全調度中最具挑戰性的情況下仍能維持預測的準確性。

特徵參數類別	代表參數	對光伏功率影響機制	數據來源	適用預測
日射量	GHI、DNI、DHI	決定光伏轉換效率和即時功率輸出	氣象站、NWP	超短期~長期
氣象因子	溫度、濕度、雲量、降水	影響光伏轉換效率	氣象站、NWP	短期~中期
空間、圖像	雲團運動軌跡、輻射係數、衛星影像	捕捉雲團快速移動，預測瞬時遮擋變化	全天空影像、衛星影像、雷射雲幕儀	超短期
歷史、時間序	歷史光伏數據、時間(小時/月/年)	捕捉系統慣性、時序相關性和季節性規律	歷史數據集	超短期/短期

表 2. 光伏預測核心輸入特徵參數總覽表

(2) 預測技術回顧：主流模型與應用

光伏發電預測技術是優化儲能排程的基石，其發展歷程涵蓋了傳統統計到機器學習和深度學習等多種模型如下：

A. 傳統統計模型：

傳統統計模型在機器學習興起前，是時間序列分析與預測的主要方法，這些方法的核心在於透過明確的數學假設，來解釋資料的內在結構。其中，最基礎的代表是線性迴歸模型，它假設觀測值可以透過多個獨立變數的線性組合來預測，並加上一個符合特定假設（例如不相關、等變異數）的隨機誤差項。另外還有自回歸整合移動平均模型 (ARIMA)，是處理非平穩時間序列的強大工具，其核心本質在於透過差分運算，將非平穩序列轉換為平穩序列，並結合自回歸 (AR) 和移動平均 (MA) 成分來捕捉序列的內部相關性，在處理時間序列數據中的線性趨勢方面表現出色，並且具有較好的可解釋性，也是時間序列分析的基礎模型^{16、17}。然而，光伏發電量受天氣、日照強度、溫度等高度非線性因素的複雜影響，導致其波動性極大，傳統統計模型在捕捉和處理這些複雜的非線性波動時，往往顯示出明顯的局限性。

B. 機器學習模型：

機器學習模型被視為一種能從資料中自動學習並進行預測或決策的數學框架，核心目標是找出輸入資料（特徵）和輸出結果（標籤）之間的隱藏模式，並將其泛化到新的、未見過的資料上。然而根據學習方式和應用場景，機器學習模型大致可以分為以下幾類：

- a. 監督式學習 (Supervised Learning)：從帶有標籤的資料中學習，例如預測房價、分類郵件是否為垃圾郵件。
- b. 非監督式學習 (Unsupervised Learning)：從沒有標籤的資料中尋找模式，例如將客戶分群、降維。
- c. 強化學習 (Reinforcement Learning)：透過與環境互動、接收獎勵或懲罰來學習如何做出最佳決策。

其中，極限梯度提升 (XGBoost) 是一種監督式學習模型，以集成學習為核心策略，透過迭代優化和修正錯誤的方式，結合多個決策樹的力量，產生一個比任何單一決策樹都更強大、更精準的最終預測模型(如圖 3 所示)¹⁸⁻¹⁹。由於它能處理變數間的線性與非線性關係，並有效地辨識出複雜的模式，因此在光伏預測領域受到廣泛青睞。而在 Rodriguez 等人的研究中還表明，XGBoost 於光伏發電預測中表現優於傳統統計模型（如 SARIMA）和某些深度學習模型（如 LSTM），能夠更精確地捕捉數據中的複雜模式，並在訓練和驗證中實現更高的

R 平方值和更低的誤差²⁰。




圖 3. XGBoost 通用架構

C. 深度學習模型：

深度學習模型是由機器學習模型的延伸，主要基於人工神經網路的架構，由多個神經網路層(又稱隱藏層)堆疊而成，核心特徵在於透過多層神經網路從大量資料中自動學習抽象特徵，並捕捉複雜非線性關係，這種能力使其在圖像識別、自然語言處理等高難度任務上取得了前所未有的突破。其中長短期記憶網絡（LSTM）這種深度學習模型專為捕捉非線性時間動態並處理具有短期和長期依賴性的時間序列而設計，在處理非線性、複雜動態數據方面表現出色²¹⁻²²，架構如圖 4 所示。儘管在某些處理數據量較小的研究中，XGBoost 的整體性能可能更優，但 LSTM 在捕捉數據深層次的非線性特徵和序列依賴性

方面仍具有獨特優勢¹⁷。




圖 4. LSTM 網路結構

D. 混合模型：

為克服單一模型的局限性，結合不同模型優勢的混合預測方法（例如 ARIMA-LSTM-XGBoost 混合模型）被廣泛研究及應用²³⁻²⁴。這些混合模型能夠同時處理數據中的線性、非線性及複雜模式，顯著提高預測的準確性和穩定性。例如，ARIMA 可以處理數據的線性部分和長期趨勢，LSTM 負責捕捉殘差中的非線性高頻波動，而 XGBoost 則可以預測整體趨勢，最終通過線性回歸等方法整合多個模型的預測結果，實現更全面的預測能力¹⁷。

在選擇光伏預測模型時，需要權衡準確性、計算複雜度和數據需求，雖然機器學習和深度學習模型通常能提供更高的準確性，但它們往往需要更多的計算資源和高質量的訓練數據。相比之下，傳統統計模型雖然簡單，但在處理複雜光伏數據時準確性可能不足。混合模型則在

準確性上有所提升，但同時增加了使用和維護的複雜性。這種權衡表明，模型選擇並非僅追求最高準確度，而是需根據特定應用場景的運營限制、數據基礎設施和計算能力來決定最佳平衡點，例如對於需要低延遲和快速計算的實時電網操作，模型必須在準確性和速度之間取得平衡。

此外，光伏預測技術正從提供單一「點預測」發展到提供區間「機率預測」。由於光伏發電固有的不確定性，單一預測值無法充分傳達潛在的波動範圍。機率預測則能提供一系列可能的結果及其發生機率，例如預測區間，從而為電網運營商和 BESS 排程人員提供更全面、更實際的未來發電情況視角²⁵。這使得決策者能夠在考慮不同風險水平的情況下制定更穩健的策略，對於在不確定性下管理電網穩定性和市場參與至關重要。因此，未來光伏預測的實踐應更側重於開發和利用機率預測方法，以實現更精密的風險優化能源管理策略。

(2) 傳統排程的局限性：經驗與即時反應的不足

傳統的電力系統主要依賴火力與水力機組來提供電網輔助服務，但這些機組在執行頻率調節等任務時，常面臨效率降低與營運成本增加的兩難。隨著再生能源的快速發展，其固有的間歇性、隨機性與難以預測性，使得電網日益複雜，而過去被動地、仰賴操作員經驗或單純即時訊號反應的調度模式已顯得不足。

傳統調度模式的「被動性」與「局部優化」是其主要問題。這些方法本質上是被動的，僅在頻率偏差或負載高峰發生後才做出反應，這不僅導致效率低下，也因為其僅針對特定、單一條件進行優化，而無法滿足現代電網的整體動態需求。這種被動和局部優化的特性，最終導致系統整體效益未能最大化，並降低了電網的韌性。

此外，傳統排程方式也與儲能系統的壽命存在潛在衝突。電池儲能系統的有效壽命受充放電循環次數和放電深度等因素影響，但傳統的、基於規則的調度方法通常不會將電池衰退模型納入考量。它們可能為了滿足即時需求或簡單的經濟信號，而忽略對電池長期健康的影響，無意中加速電池衰退，增加其總持有成本。

因此，轉型朝向高再生能源滲透率的電網，迫切需要從被動式能源管理轉向主動式預測優化。這類策略能預見電網需求、再生能源輸出與價格變化，讓儲能系統在最佳時機進行充放電操作，不僅能提升削峰填谷、能量套利和頻率調節的效益，還能透過更智能的充放電循環，兼顧電池的長期健康與壽命。這不僅能延長資產使用壽命、降低更換成本，更顯著提升了儲能投資的整體財務吸引力與永續性。

(3) 預測技術的革新：實現儲能排程的「主動預見」

光伏發電預測技術的應用，正將儲能排程從過去的被動反應模式，轉變為主動預見的智慧化管理。這種轉變的核心在於儲能系統不再僅

僅是應對電網事件的工具，而是能根據對光伏發電量、電網負載與電力市場價格的精準預測，預先規劃並優化其充放電行為，這項能力能極大化儲能系統在電網穩定與經濟效益上的價值。

在電網穩定方面，精準的預測有助於平滑化再生能源輸出，並在夜尖峰或突發狀況時提供及時支援，顯著提升電網韌性。例如，儲能系統能透過預測有效管理電網的「鴨子曲線」現象，將日間過剩的太陽能儲存起來，並在傍晚需求高峰時釋放，減少棄光並降低對傳統電廠的依賴。

在經濟效益方面，預測技術使儲能系統能更精準地參與電力市場，實現能量套利（低買高賣）。這種主動管理模式將能顯著降低整體發電調度成本，包括燃料成本和機組啟停成本。此外，精準的預測還有助於決定最佳的儲能系統容量，避免初期投資過度或配置不足，並能指導儲能系統制定動態且優化的充電排程，確保電池在實現最大收益的同時，兼顧其長期健康與壽命。

總結來說，對前瞻預測技術的投資是一項具備明確回報的戰略性財務決策。它賦予儲能系統主動管理能源流動的能力，將資源分配效率最大化，並將昂貴的被動應對措施降至最低，從而為未來的電網提供更強大的穩定性與韌性。

2.3 無程式碼 AI 平台在能源領域的應用

(1) 新興趨勢：降低技術門檻

無程式碼 (No-code) AI 平台是一種創新的軟體開發方式，它透過提供視覺化的拖放介面、預建元件和模板，讓使用者無需編寫任何程式碼即可建構、訓練和部署 AI 應用程式。這些平台將複雜的機器學習功能與軟硬體元件（如伺服器 and 安全性）抽象化，將其包裝成直觀易用的工具，例如 Airtable 的 Omni AI（對話式 AI 應用程式建構工具）和 Microsoft Power Platform（商業應用程式開發平台）。研調機構 Gartner 預測到 2025 年全球 70 % 的新應用程式將使用低程式碼/無程式碼技術開發，顯示其快速成長的趨勢和巨大潛力。

無程式碼 AI 的核心優勢在於它降低了 AI 應用的技術門檻，賦予非技術背景的專業人士（即「公民開發者」）直接參與開發的能力。這使得他們能夠運用深厚的領域知識，快速將其轉化為實際的 AI 解決方案，而無需依賴資料科學家或軟體工程師資源²⁶。

在能源領域，無程式碼 AI 平台展現了巨大的應用潛力，能加速產業的數位化進程。這些平台可用於快速開發多種應用，包括能源預測模型（如光伏發電和負載預測）、儲能排程工具、能源消耗監控儀表板和預測性維護解決方案。這種能力對於管理分散式能源資源（DERs），如屋頂太陽能、本地化儲能系統和微電網尤為重要，因為

操作人員能夠快速建構和部署應用程式，整合來自各種 DERs 的數據，並應用 AI 進行深入分析。這種能力不僅能提高運營效率、優化決策品質，還能讓組織快速開發出更貼近需求的解決方案，最終增強企業在複雜能源網路中的應變能力，有助於推動電力系統轉型成更分散化和智慧化的電網²⁷。

(2) 優勢與挑戰：快速迭代、易於部署與客製化、數據安全性

無程式碼 AI 平台為能源領域帶來了顯著優勢，它能大幅縮短應用開發週期，這意味著使用者可以更快地建立原型（驗證新點子與功能）、進行測試（確保正常運作）與完成部署（上線提供使用），整個過程更加簡易。這些平台也因為減少了對專業程式開發人員的依賴，能有效降低開發成本並減輕內部 IT 團隊的負擔，同時自動處理底層技術基礎設施（伺服器、作業系統與安全設定等），簡化了應用程式的部署和日常維護。然而，許多平台都內建了 AI 與機器學習（ML）工具，能自動分析數據、洞察趨勢並優化作業流程，這使得做決策不再依賴經驗或直覺，而是轉向數據驅動，讓每一次的判斷都更為精準、更具說服力。但是這些平台的應用也伴隨著挑戰，它們在處理需要高度客製化或複雜的 AI 模型時，靈活性與功能可能受限，像是無法滿足能源領域中高精度故障診斷或多目標優化等高難度需求。同時，AI 系統的準確性高度依賴數據品質，但能源數據可能存在缺失、不一致或

歷史偏見等，這對於缺乏經驗的使用者而言，在數據預處理和模型驗證上會構成挑戰。此外，能源數據的敏感性也帶來了數據安全與隱私問題，不當配置或缺乏安全意識可能引入安全漏洞。最後，若無程式碼平台要與現有複雜的管理系統（如 SCADA、EMS/DMS）進行深度整合也存在難度，因為預建介面可能不足或缺乏修改彈性。因此，無程式碼 AI 平台雖然非常適合相對簡單的應用或工作流程，但對於需要精細控制、強大安全功能以及深度整合的複雜、高風險電網優化任務，仍需要搭配傳統程式或低程式碼方法來使用。

三、研究方法

3.1 數據蒐集與前處理

本研究使用網路上的公開氣象數據，採用輕量化的建模方法，旨在建立一個高效且易於複製的發電量預測模型。主要數據包含氣象觀測資料、氣象預報資料及案場實際光伏發電量數據，其具體來源與內容說明如下：

- 觀測數據：

- ◇ 氣象觀測資料：從農業氣象觀測網監測系統位於農試鳳山所的觀測站點，蒐集該地區的觀測氣溫與觀測日射量資料。

◇ 案場光伏數據：從台電鳳山智慧綠社區的能源管理系統，蒐集該地區的觀測光伏發電量與觀測日射量數據。

● **預報數據：**

- 氣象預報資料：從交通部中央氣象署取得預報氣溫資料，作為模型預測光伏發電量的輸入變數。

在數據處理方面，本研究的數據集已包含年月日時的時間序列特徵，使得每一筆數據都具備明確的時間屬性。在模型建構階段，數據並未進行額外的前置處理，直接使用原始數據來評估 no-code AI 平台的處理能力與模型表現。

3.2 光伏預測模型建立

本研究利用 no-code AI 平台快速建構光伏發電預測模型，以驗證此類工具在能源預測應用上的可行性。整個建模過程依循階段性的串聯邏輯，共建置了三個模型，其流程與輸入、輸出變數如下：

● **No-code AI 平台操作流程(如圖 5)：**

首先，將訓練模型的模型特徵與用來預測的輸入特徵分別彙整成兩個 Excel 檔案。接著，點選平台上的上傳檔案按鈕將這兩個檔案上傳。

在 dataset:df{X,y(target)} 下方欄位打入模型特徵 Excel 檔案的名稱，並在 predict:X save w/id 下方欄打入輸入特徵 Excel 檔案的名稱，再勾選 predict:X。接著，點選 Parse Field 後，平台會將檔案資料導入至介面，再從 select as target 欄位選擇輸出目標，然後須勾選 time to serials(YMW)，並按下 Parse Data 後，平台會導入時間序列特徵並對數據進行初步解析，總結資料量及是否有缺值等資訊。然而在建構模型選擇上，本研究使用 XGBRegressor 演算法，且並未進行特定的參數調校，以評估其在預設條件下的預測能力。最後，按下 Submit 按鈕，即可取得包含 MAE、MSE、R2_score 等評估指標數據，也可下載輸出結果 Excel 檔案。

1. 上傳已分類數據

2. 缺失值處理

3. 選定演算法

4. 執行

5. 結果輸出

- 預測值
- 誤差均值
- 誤差分布圖

圖 5. No-Code AI 平台介面簡介

● 模型及特徵參數：

模型一：日射量預測模型（農試鳳山所）

- [1] 模型特徵：農業氣象觀測網的觀測溫度與觀測日射量。
- [2] 輸出目標：農試鳳山所的預測日射量。
- [3] 模型功能：利用模型對氣象數據的學習能力，將交通部中央氣象署發布的預報氣溫資料作為輸入，進而取得農試鳳山所觀測站的預測日射量。

模型二：日射量預測模型（台電鳳山區營業處）

- [1] 模型特徵：農試鳳山所的觀測日射量與台電鳳山區營業處的觀測日射量。
- [2] 輸出目標：鳳山區營業處的預測日射量。
- [3] 模型功能：將模型一所得到的農試鳳山所預測日射量作為輸入，藉此取得台電鳳山區營業處的預測日射量。

模型三：光伏發電量預測模型（台電鳳山區營業處）

- [1] 模型特徵：台電鳳山區營業處的觀測日射量與觀測光伏發電量。
- [2] 輸出目標：預測光伏發電量。
- [3] 模型功能：將模型二所得到的台電鳳山區營業處預測日射量作為輸入，最終取得該案場的預測光伏發電量。

此三階段串聯的建模策略旨在透過多模型協作，逐步將來自不同來源的氣象數據轉換為最終所需的光伏發電量預測結果。

3.3 能源管理系統導入與數據整合

本研究不僅於模型的建立，更進一步將建構完成的 XGBoost 光伏預測模型導入鳳山智慧綠社區的能源管理系統（Energy Management System, EMS），以實現預測數據的落地應用與可視化。整體架構旨在建立「氣象數據—AI 推論—現場決策」的自動化數據流，具體實施流程如下：

- [1] 數據流架構與自動化介接：透過腳本建立自動化排程，每日定時透過 API 抓取中央氣象署發布的次日逐時天氣預報溫度數據，將其輸入至已訓練完成的最佳權重模型進行推論，產出次日光伏發電量預測值。
- [2] EMS 介面整合與可視化：預測結果寫入 EMS 的後端資料庫，並即時以兩條曲線並列方式呈現於前端監控介面：
 - 預測曲線：顯示 AI 模型計算出的發電趨勢，供運維人員提前掌握明日的能源供給量。
 - 實際曲線：接入現場逆變器（Inverter）的回傳數據。透過兩條曲線的即時比對，運維人員可直觀判斷當前的發電狀態是

否符合預期。若實際值大幅偏離預測值(例如突發性雲遮蔽)，可進一步協助判斷是否需調整能源管理策略。

- [3] 支援電池儲能排程決策：數據整合的核心價值在於為電池儲能系統(ESS)提供決策依據。未來 EMS 系統可依據光伏預測結果，預估次日的「淨負載(Net Load)」曲線，在預測發電過剩的時段(如正午高輻照時段)，系統可預先規劃電池充電指令；在預測發電不足的時段(如傍晚或陰雨天)，則規劃放電指令，奠定「削峰填谷(Peak Shaving and Valley Filling)」與「時間電價套利(Time-of-Use Arbitrage)」的自動化基礎。

四、研究結果與討論

本章節旨在針對利用前述方法所建立的 no-code AI 光伏發電預測模型進行詳盡的性能評估與診斷。透過誤差指標、系統性偏差等圖表分析，進一步量化模型的預測能力，並識別出模型潛在的結構性弱點。

接著將依序探討模型在不同訓練資料尺度下的總體預測準確度，並透過誤差指標的差異分析診斷模型的穩健性問題。最後，針對預測偏差進行季節性探討，進而為光伏預測模型的優化與部署提出改善方向。

4.1 總體預測準確度與訓練週期穩定性分析

(1) 決定係數(R^2)比較與模型解釋力評估

決定係數 (Coefficient of Determination, R^2) 是衡量模型擬合度 (Goodness of Fit) 的關鍵指標，藉此評估模型解釋光伏發電變異性的能力。圖 6 比較了利用不同時間跨度資料所建立模型的 R^2 表現，揭示現有預測模型穩定性仍有不足。根據圖表顯示，當採用與預測目標年份 (2025 年) 最接近的 2024 年模型 (利用該年歷史資料集所建立之模型) 進行預測時， R^2 值約為 0.59，表明模型僅能有效解釋約 59% 的光伏發電變異。此外，觀察跨年份訓練組合 (如 2022-2024 或 2023-2024)，其 R^2 值進一步穩定在 0.60 之上，顯示融合近期多樣數據能提供較穩健的擬合效果。

然而，若回溯檢視較早期的單一年度模型，可發現其解釋力呈現顯著的衰退與波動。尤其 2022 年模型的 R^2 值落至最低點，僅約 0.21，意味著該年度的數據特徵難以有效捕捉 2025 年的發電變化；而 2021 年與 2023 年模型則分別位於約 0.28 和 0.39 的低水準。這種單年度 R^2 值在 0.21 至 0.59 之間的劇烈震盪，顯示該時間序列的底層規律在不同年度間具有高度的相異性。此結果也說明了光伏發電數據在本質上屬於非穩態序列，即太陽輻射與實際發電量之間的轉換效率參數，並非恆定不變，而是隨著時間推移發生了結構性的變化。

進一步探討其物理成因，這些結構性變化可能源於兩大因素：首先是光電組件與系統的持續性物理衰退，導致光電轉換效率逐年降低；其次是未被模型顯性捕捉的長期環境趨勢，例如氣候變遷引起的日照型態改變或面板表面清潔度的長期變化。這些因素導致舊有數據（如 2021-2022 單一年度）中包含了不再適用於當前的「過時參數」或「污染參數」。因此，為確保預測模型的長期穩健性，應避免依賴長期固定的訓練資料集，轉而採用「滾動式訓練」策略。透過定期淘汰過舊的歷史數據，並持續引入反映最新系統狀態（如 2024 年）的觀測值，模型將能更靈活地調整並適應這種持續性的物理衰減趨勢，從而維持較高水準的預測解釋力。




圖 6. 不同時間跨度訓練數據所建立模型的決定係數比較

(2) 誤差指標 (RMSE/MAE)之不同時間尺度量化與差異分析

本研究採用均方根誤差 (RMSE) 與平均絕對誤差 (MAE) 作為核心指標，利用 2025 年 4 月至 8 月的實際觀測數據作為預測的驗證集，探討光伏發電預測模型在不同訓練數據跨度下的性能表現，並進一步比對「小時」與「日」兩種時間尺度的誤差特徵。藉由數據分析顯示（如下圖 7、8 及表 3），訓練數據集的量體與時間跨度是決定預測精確度的關鍵因素。當模型僅使用較早期單一年份（如 2021、2022、2023 年）的數據進行訓練時，受限於特定年份的氣候異常與極端天氣事件頻率，模型難以有效泛化至 2025 年的預測情境。其中，以 2022 年單獨訓練的模型誤差最高，其日尺度的 MAE 高達 839.7 kWh，標準化後的平均絕對誤差 (MAE %) 達 58.4 %，顯示單一歷史年度的數據不足以讓模型學習到具備長期代表性的氣候特徵。

然而在觀察最佳的訓練跨度時，可發現除了融合多樣氣候特徵的「2022 至 2024 年」跨年份模型表現優異（日尺度 MAE 降至 449.3 kWh）外，僅使用「2024 年」單一年度數據的模型亦展現了相對低的誤差（日尺度 RMSE 為 461.4 kWh，MAE % 僅 32.1 %）。針對 2024 年單一模型能逼近最佳跨年份模型的現象，可能的原因在於「數據的時間相近性」與「系統狀態的即時性」，由於預測的目標為 2025 年，2024 年的氣象特徵（如太陽照度分佈與雲層動態）與預測目標期間具有高

度的氣候延續性，且數據內嵌了光伏系統當前的硬體效率狀態（含衰退與環境髒污因子）；相比之下，過舊的數據（如 2021 年）可能因氣候變遷或設備狀態差異，導致歷史規律不再適用於當前預測，這也解釋了為何納入 2021 年數據的「2021-2024 模型」誤差反而微幅上升。儘管 2024 單年模型表現還不錯，但考量到長期運維的風險，「2022-2024 跨年份模型」仍然是相對較佳的選擇，因為該模型在維持較高準確度的同時，融合了更多樣化的歷史氣候樣本，在面對未來可能發生的氣候波動時，具備比單一年度模型更佳的穩健性。

另外在時間尺度的比較分析中，也發現了明顯的「誤差平滑效應」。雖然最佳模型（2022-2024）在預測「小時」級別的瞬時功率時，仍有約 49.4 % 的 MAE % 波動，顯示模型在捕捉雲層遮蔽等快速非線性變化上仍有挑戰；但當分析尺度拉長至「整日」總發電量時，小時預測中正向(高估)與負向(低估)的累積預測誤差在時間積分過程被相互抵銷，使得日尺度的 MAE % 大幅下降至 31.2 %，約有 18 個百分點的準確度提升。此結果表明該模型雖然在較微觀的即時控制上需預留較大裕度，但在較宏觀的日前（Day-ahead）儲能排程與總量規劃上具有較高可靠性。

最後，透過分析 RMSE 與 MAE 的比率及其標準化分佈（Z-Score Distribution），可進一步了解模型誤差分佈的特性。在小時尺度下，所

有模型的 RMSE/MAE 比率均維持在 1.28 至 1.32 的高水平，由於 RMSE 對大誤差賦予較高權重，因此比率大於 1.25 意味著誤差分佈具有重尾性（三種誤差分布樣態如下圖 9 所示），即系統誤差並非呈現標準常態分布，而是系統性地存在少數但劇烈的瞬時預測失誤（如突發暴雨導致的巨大偏差）。其中 2022-2024 模型來看，RMSE/MAE 比率處在 1.30 的高水平，經過標準化後的誤差分佈呈現高狹峰特徵（如下圖 10 所示），意味著模型在大部分時間內預測較為精準（誤差集中於 0 附近），但少數瞬時的極端波動（如雲層快速遮蔽），導致其尾部延伸較長，存在較大的預測失準。相對地，當分析尺度轉為日單位時，所有模型的比率普遍下降至 1.11 至 1.21 區間，低於常態分佈的理論基準值（約 1.25）。而同樣以 2022-2024 模型來看，整體誤差分佈變得較為平坦且均勻，不像小時誤差那樣具有極端的尖峰特徵，但觀察標準化圖表的尾端（ $Z > 3$ 區域），日誤差的機率密度曲線仍略高於標準常態分佈，這表明時間的平滑效應雖然有效稀釋了瞬時波動，使大部分的日預測誤差控制在穩定範圍內，但並未完全消除極端離群值的發生機率。換言之，日級別預測在平均表現上雖具備較高的可靠性與穩定度，但在面對極少數的極端氣候異常日時，系統仍需預留一定的安全裕度，以應對那些無法被完全平滑掉的尾部風險。基於此分析，為了進一步抑制小時尺度的重尾誤差，未來的模型優化策略應從

單純的歷史數據驅動，轉向引入更高解析度的氣象特徵，例如導入雲量、雲層分佈動態或區分直達/擴射日射量 (DNI/DHI) 等作為關鍵輸入變數，以協助模型提前識別並適應多雲或陰雨天氣的瞬時功率波動，從而提升小時級別預測的精確度與穩定性。




圖 7. 不同時間跨度訓練數據所建立模型之「每小時」誤差指標比較




圖 8. 不同時間跨度訓練數據所建立模型之「每日」誤差指標比較




圖 9. 標準誤差分佈型態




圖 10. 2022-2024 模型標準化誤差分佈型態比較

訓練數據集 跨度	指標 類型	RMSE (kWh)	MAE (kWh)	RMSE/MAE 比率	誤差百分比 (RMSE %/MAE %)
2024	小時	72.2	54.8	1.32	66.0 % / 50.1 %
	日	568.1	461.4	1.23	39.5 % / 32.1 %
2023	小時	88.1	69.0	1.28	80.5 % / 63.1 %
	日	781.8	699.2	1.12	54.4 % / 48.6 %
2022	小時	100.7	78.3	1.29	92.1 % / 71.6 %
	日	934.8	839.7	1.11	65.0 % / 58.4 %
2021	小時	95.7	74.9	1.28	87.5 % / 68.5 %
	日	893.6	800.1	1.12	62.1 % / 55.6 %

2023-2024	小時	70.6	54.3	1.30	64.5 % / 49.7 %
	日	546.1	455.7	1.20	38.0 % / 31.7 %
2022-2024 (最佳模型)	小時	70.5	54.0	1.30	64.4 % / 49.4 %
	日	544.7	449.3	1.21	37.9 % / 31.2 %
2021-2024	小時	71.8	55.8	1.29	65.7 % / 51.0 %
	日	574.2	479.8	1.20	39.9 % / 33.4 %

表 3. 不同時間跨度訓練數據所建立模型的誤差指標數值

4.2 預測總量偏差與季節性探討

對預測偏差的分析是診斷模型系統性錯誤的關鍵。偏差不僅影響預測的準確性，更直接影響電力系統的調度與資源規劃。

(1) 實際與預測總量對比的系統性偏差

首先針對 2025 年度的總發電量進行預測與實測值的總量對比，以診斷模型是否存在方向性的系統偏差。分析結果顯示，所有訓練跨度的模型在預測 2025 年表現時，均呈現了顯著的「系統性高估」現象。具體而言，2025 年 4 月至 8 月的實際觀測總發電量約為 187,869 kWh，然而各模型的預測值均大幅超出此數值，顯示出模型對於該年度發電量基線的下滑趨勢捕捉不足。其中，以 2022 年單一年度數據訓練的模型誤差最為嚴重，其預測總量高達 291,200 kWh，出現了 61.3 % 的巨大正向偏差；這反映出 2022 年可能為歷史上的高發電年份，若直接將其高基線應用於發電量顯著衰退的 2025 年，將導致嚴重的預測失準。

接著在比較不同模型的表現時，出現了誤差指標與總量偏差指標的分歧，在前一章節的誤差分析（RMSE/MAE）中，「2022-2024」跨年份數據的模型因具備最佳的抗波動性與泛化能力而被認定為所有模型中的最佳模型；然而，在年度總量偏差分析中，卻是僅採用「2024」單一年度數據的模型表現最為接近實際值（預測量約 222,419 kWh，誤差率 22.6 %），優於 2022-2024 模型的 27.0 % 誤差率。

針對此現象可能的原因在於「歷史平均的慣性」與「系統狀態的時效性」。2022-2024 跨年份模型雖然透過融合多樣樣本降低了每日預測的隨機誤差（RMSE 較低），但其訓練數據中納入了 2022 年同期的歷史最高發電紀錄（4-8 月高達 311,981 kWh）與 2023 年的高檔數據（290,358 kWh），這些顯著高於 2024 年（265,545 kWh）的歷史數據，使得模型在計算總量時，不可避免地被歷史高值拉高了預測基線。相比之下，2024 年單一模型雖然在應對每日氣候波動的穩健度上不如跨年份模型，但因 2024 年本身的發電總量（約 265,545 kWh）已較 2022 年高峰期衰退約 15 %，且內嵌了最新的設備老化狀態等現況，因此在預測同樣較低迷走勢的 2025 年總發量（同期僅 187,869 kWh）時，反而能提供比跨年份模型更貼近現況的基線估計。

最後綜合分析 2025 年實際發電量（187,869 kWh）遠低於所有歷史年份（2021-2024）的現象，推測導致此系統性高估的主因是複合性的，

一方面是光電模組可能因長期運行產生的老化衰退 (Degradation) 或持續性的污損積塵，導致 2025 年的整體光電轉換效率出現了非預期的系統性滑落；另一方面是 2025 年可能經歷了比訓練期間(2021-2024)更頻繁的日照不足或長時間陰雨氣候，導致實際日照資源低於歷史平均水平。就電網調度實務而言，此類對未來發電能力的持續性高估具有潛在風險，若調度中心依據此錯誤預期進行規劃，恐致備用容量準備不足，進而引發電力市場的緊急採購成本上升。因此，未來的模型優化應該引入「衰減因子」或更敏感的「氣候趨勢修正項」，以校正此種可能由歷史慣性所導致的系統性偏差。




圖 11. 各時間跨度模型所得預測總發電量與實際觀測總發電量比較

(2) 季節性誤差模式與外部因子耦合分析

接著利用量化數據將預測誤差依據季節特徵進行解析，透過對比「春季 (4-5 月)」與「夏季 (6-8 月)」的預測總量與實際觀測值，揭示模型誤差在不同季節呈現的顯著差異，並進一步探討不同訓練資料

跨度模型在捕捉氣候特徵上的差異。數據分析結果指出夏季(6-8月)是所有預測模型的共同盲區。2025年夏季(6-8月)的實際總發電量約為 113,509 kWh，然而在所有測試的模型中被認為最佳的「2022-2024 跨年份模型」預測值卻高達 156,077 kWh，產生了約 37.5% 的系統性高估；即便是對近期衰退趨勢反應最敏銳的「2024 單年模型」，在夏季仍給出 153,934 kWh 的樂觀預測。此一普遍性的高估現象表明，夏季的誤差主因已超越了歷史數據選擇的範疇，而是源於強烈的「外部氣候耦合效應」，即是當多個氣象因子同時發生交互作用，並對發電系統產生非線性的影響，例如夏季極端高溫導致的模組效率熱衰退，或午後熱對流（雷陣雨）造成的日射量驟降，甚至是颱風極端事件的衝擊。這些非線性的物理折損未被模型充分學習，導致採用何種年份的訓練數據，均無法避免大幅度的正向偏差。

年度 (年)	2025 (實際)	2024	2023	2022	2021	2023- 2024	2022- 2024	2021- 2024
春季 (kWh)	70645	71809	94903	98147	103063	79048	77764	80590
誤差 (%)	-	1.6	33.8	29.0	33.0	8.2	9.0	12.8
夏季 (kWh)	113509	153934	181028	198973	191589	155109	156077	161293
誤差 (%)	-	35.6	59.5	75.3	68.8	36.6	37.5	42.1

表 4. 春/夏季不同時間跨度模型的預測發電總量及誤差




圖 12. 春/夏季預測發電量誤差比較

相對地在春季(4-5月)，模型展現了截然不同的性能特徵，其中「近期數據價值」的優勢尤為突出。2025年春季實際發電量為70,645 kWh，在此期間 2024 單一年度模型展現了較高的預測能力，其預測值為71,809 kWh，與實際值的誤差僅1.6%；相比之下，2022-2024跨年份模型的預測值為77,764 kWh，誤差約為10.1%。2024模型之所以在春季勝出，可能是它僅依賴最近期的數據訓練，從而精準捕捉到了光伏系統最新的「老化衰退狀態」與「近期氣候慣性」；反觀跨年份模型雖然在統計穩健性(RMSE)上表現較佳，但因摻雜了2022-2023年較舊且可能系統效率較高的歷史數據，導致其預測基線被拉高，在系統狀態相對穩定的春季反而不如2024模型精準。

綜合上述分析，夏季的高估可能屬於結構性的物理限制，必須引入「溫度」與「上空雲系識別」等外部物理修正機制，才能有效消除那37.5%的巨大偏差。而春季的精準度則高度依賴於數據的時效性，2024模型在春季相對優異的表現提供了未來模型的優化方向：在氣

候與系統狀態相對穩定的季節，應採用「加權融合策略」，即在跨年份模型的穩健基礎上，賦予近期數據更高的權重，以兼顧長期氣候的適應性與短期系統衰退的精準度。

五、結論與未來工作

5.1 結論

本研究利用 XGBoost 演算法結合開源氣象數據，針對光伏發電預測模型進行了不同訓練時間跨度的比較分析，並深入探討了模型在實際應用中的季節性特徵與物理限制。綜合數據與誤差分析，總結如下：

- [1] 數據多樣性與近期偏差的權衡： 分析發現採用「2022-2024 跨年份數據」訓練的模型，因樣本涵蓋了多樣化的氣候特徵，在統計指標（RMSE）上表現最為穩健，可判定其抗波動性較佳。然而，僅採用「2024 單一年度數據」的模型，因精準捕捉了系統近期的老化衰退趨勢與氣候慣性，在預測 2025 年春季時展現了較高的精準度（誤差僅 1.6 %），這顯示在系統狀態快速變化的情境下，「近期數據」具有不可忽視的預測價值。
- [2] 季節性誤差結構的非均勻性： 透過季節性拆解分析，揭示了模型誤差存在顯著的「春季精準、夏季失準」現象。在春季（4-5 月），模型預測值與實際值高度吻合；然而進入夏季（6-8 月），所有模型均出現了嚴重的系統性高估（誤差幅度達 37.5 %）。

- [3] 夏季高估的物理成因：夏季的巨大偏差證實了「外部氣候耦合效應」的影響，現有模型未能充分考量夏季極端高溫（模組溫度 $> 50^{\circ}\text{C}$ ）可能導致的光電轉換效率熱衰退，以及午後熱對流（雷陣雨）造成的日射量驟降。因此模型傾向於依據高日射量推算高發電量，忽略了伴隨而來的熱損耗與對流遮蔽，導致對於夏季發電潛力過度樂觀預期。

5.2 未來工作

基於上述，未來研究將聚焦於解決系統性高估問題並提升儲能應用效益，具體規劃如下：

- [1] 引入容量衰減與氣候趨勢修正機制（修正系統性偏差）：針對模型傾向高估未來發電量的現象，未來的模型優化可能須引入「容量衰減因子」或更「氣候趨勢修正項」，不再僅依賴歷史平均值，而是將系統老化的物理衰退率以及長期氣候趨勢作為變數輸入模型，以主動校正由「歷史慣性」所導致的系統性高估偏差，確保長期預測基線貼近案場現況。
- [2] 導入高解析度氣象特徵（提升小時級精確度）：為進一步抑制小時尺度的誤差波動，未來的模型優化策略應從單純的歷史數據驅動，轉向引入更高解析度的氣象特徵。例如除了基本的全天空日射量（GHI）外，可能須導入雲量、雲層分佈動態或區分直達/擴散日

射量（DNI/DHI）等作為關鍵輸入變數，這將協助模型提前識別並適應多雲或陰雨天氣下的瞬時功率波動，從而提升小時級別預測的精確度與穩定性。

- [3] 開發「長短期加權融合」策略：鑑於 2024 模型在春季的優異表現與 2022-2024 模型在整體的穩健性，未來在氣候穩定的季節賦予近期數據較高權重，在極端波動季節則依賴長期數據的泛化能力，以兼顧趨勢捕捉與風險控制；同時，針對夏季高溫導致的熱衰退誤差，可能須建立模組溫度的動態回饋機制，將溫度係數損失納入預測演算法中，以物理機制消除夏季的結構性高估。
- [4] 優化電池儲能排程演算法：待模型優化後，下一步將預測結果直接輸入至最佳化演算法（如線性規劃或動態規劃）中，考量時間電價(TOU)、契約容量限制及需量等，生成最佳的充放電排程表，驗證預測技術提升案場經濟效益的實際幅度。

六、參考文獻

- [1] REN21, "Renewables 2025 Global Status Report," Renewable Energy Policy Network for the 21st Century, Paris, France, 2025. [Online]. Available: <https://www.ren21.net/gsr>
- [2] 台灣電力公司, "儲能神助攻 即戰力與商機受青睞," 台電月刊, no. 715, July 2022.
- [3] Amit Mathrani, "Battery energy storage systems: The foundations of a resilient energy future in the US," Coöperatieve Rabobank UA,

- Research, 2025.
- [4] Systems With Intelligence, "The Economics of Renewable Integration: How BESS Improves Grid Stability, 2025.
 - [5] California ISO, "What the duck curve tells us about managing a green grid," California Independent System Operator, Folsom, CA, USA, Fast Facts, 2016.
 - [6] R. Kurniawan Subroto, D. Gebbran, A. Barragan Moreno, and T. Dragicevic, "BESS Optimal Sizing and Scheduling for Energy Arbitrage and Frequency Containment Reserve via Dual-Loop Optimization," 2022 IEEE Transportation Electrification Conference and Expo (ITEC), pp. 941–946, July 2022.
 - [7] 經濟部能源署, "再生能源裝機容量統計 114 年 4 月份月報," 經濟部, 台灣, 2025.
 - [8] Fluence, "The evolving role of BESS: How market design can drive the next energy transition," Reccessary, MARKET INSIGHT, July 2025.
 - [9] Greg Sowder, "Energy Storage Systems: Understanding the Duration and Limitations of Energy Storage Capacity," Qmerit Network, Nov. 2023.
 - [10] 胡順惠, "台灣儲能市場估成長十倍 安永點出兩大加速關鍵," 聯合新聞網, July 2025.
 - [11] Hui-hsuan Ting, "Taiwan can't build renewables if we can't balance them," Enel X Taiwan, Sep. 6, 2021.
 - [12] Z. Reza, E. Sara, and P. Urvi, "Assessing the Utility of Weather Data for Photovoltaic Power Prediction," Syracuse University, Feb. 12 2018.
 - [13] 許時佳, "基於 PEEEMD-BiLSTM-XGboost 光伏發電功率預測方法研究," 應用數學展, pp. 5039–5049, 2023.
 - [14] B. Said, N. Gilles, and V. Cyril, "Comparative Study of Feature Selection Techniques for Machine Learning-Based Solar Irradiation

Forecasting to Facilitate the Sustainable Development of Photovoltaics Application to Algerian Climatic Conditions," *Sustainability*, 2025.

- [15] 余光正, 湯波, 陸柳"一種超短期光伏預測方法,"國家知識產權局, CN 112507793, 2023.
- [16] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed., John Wiley & Sons, 2015.
- [17] X. Huang, X. Zhuang, F. Tian, Z. Niu, Y. Chen, Q. Zhou, and C. Yuan, "A Hybrid ARIMA-LSTM-XGBoost Model with Linear Regression Stacking for Transformer Oil Temperature Prediction," *Energies*, 2025.
- [18] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD)*, San Francisco, CA, USA, 2016, pp. 785–794.
- [19] Y. Wang, Z. Pan, J. Zheng, L. Qian, M. Li, "A hybrid ensemble method for pulsar candidate classification," *Astrophysics and Space Science*, 2019.
- [20] C. K. Rodriguez-Leguizamon, J. A. Lopez-Sotelo, S. Cantillo-Luna, and Y. U. Lopez-Castrill, "PV Power Generation Forecasting Based on XGBoost and LSTM Models," 2023 IEEE Workshop on Power Electronics and Power Quality Applications (PEPQA), 2023.
- [21] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, pp. 1735–1780, Nov. 1997.
- [22] B. Lindemann, T. Muller, H. Vietz, N. Jazdi, and M. Weyrich, "A survey on long short-term memory networks for time series prediction," 14th CIRP Conference on Intelligent Computation in Manufacturing Engineering, July 2019.
- [23] M. F. Javed, M. Khan, M. Fawad, H. Alabduljabbar, T. Najeh, and Y. Gamil, "Comparative analysis of various machine learning algorithms to predict strength properties of sustainable green concrete containing waste foundry sand," *Natureportfolio*, 2024.

- [24]R. Kazemi, and M. Z. Naser, "Towards sustainable use of foundry by-products: Evaluating the compressive strength of green concrete containing waste foundry sand using hybrid biogeography-based optimization with artificial neural networks," Journal of Building Engineering, 2023.
- [25]P. Besson, W. Mahmoud, D. Raynaud, G. Tremoy, and E. E. Stredysun, "Control optimization and sizing of energy storage for PV systems using probabilistic forecasts," Virtual 5th International Hybrid Power Systems Workshop, 2021.
- [26]T. Khan, and A. Downie, "What Is No Code?," 2023. Available: <https://www.ibm.com/think/topics/no-code>.
- [27]S. Patel, "How AI Enhances Solar Energy Storage Monitoring," May 2025. Available: <https://solarai.ai/how-ai-enhances-solar-energy-storage-monitoring/>.